

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

ОТЧЁТ
по лабораторной работе № 2
по дисциплине «Вычисления на GPU»
«Базовые параллельные примитивы на GPU»
Вариант 6 - Histogram (histogram.cuh)

Выполнил: студент группы Р4135
Баряев Андрей Алексеевич

Проверил: Лукашов И. В.

Санкт-Петербург
2026

СОДЕРЖАНИЕ

Введение.....	3
1. Характеристики системы и подготовка проекта (этап 1).....	3
2. Сборка проекта и проверка эталонов (этап 2).....	4
3. Изучение и проектирование алгоритма (этап 3).....	5
4. Реализация CUDA-функции (этап 4).....	6
5. Проверка корректности (этап 5).....	7
6. Базовые измерения производительности (этап 6).....	8
7. Повторяемость измерений (этап 7).....	9
8. Серии по размеру данных и блоку (этап 8).....	10
9. Анализ результатов и выводы (этап 9).....	13
Заключение.....	14
Список использованных источников.....	15

Введение

Цель работы - изучить преобразование последовательного алгоритма в параллельную форму и получить навыки реализации, проверки и исследования производительности программы на GPU.

Задачи работы: определить характеристики системы и compute capability GPU; собрать проект и проверить эталонные реализации; изучить CPU-алгоритм своего варианта и спроектировать его параллельную реализацию; реализовать алгоритм средствами CUDA; проверить корректность на обычных и граничных данных; получить базовые измерения CPU-, собственной GPU- и библиотечной GPU-реализаций; исследовать повторяемость измерений, влияние размера данных и числа потоков в блоке; объяснить результаты.

Назначенный вариант - вариант 6, алгоритм Histogram (построение гистограммы), файл `nvidia/student/histogram.cuh`. Гистограмма - это массив из `bins` целочисленных счётчиков; для каждого входного значения `x` номер счётчика равен $\text{bin} = |\text{int}(10 \cdot x)| \bmod \text{bins}$. Сумма всех счётчиков должна быть равна числу входных элементов `N`.

Работа выполнена локально на ноутбуке с дискретной NVIDIA GPU. Все измерения проведены на одной машине в одной сессии; исходные CSV, сводки и протокол проверок сохранены в каталоге `results` рабочей копии.

1. Характеристики системы и подготовка проекта (этап 1)

Рабочая копия получена распаковкой выданного архива. Характеристики системы сохранены в файле `results/environment.txt`. Основные сведения приведены в таблице 1.

Таблица 1 - Характеристики программно-аппаратной среды

Параметр	Значение
Операционная система	Fedora Linux 43 (Workstation), ядро 7.2.8-100.fc43
CPU	Intel Core i7-4710HQ, 2,50 ГГц, 4 ядра / 8 потоков
ОЗУ	12 ГБ (DDR3: 4 ГБ + 8 ГБ)
GPU	NVIDIA GeForce GTX 860M (GM107M), 2 ГБ
Compute capability	5.0 (CMAKE_CUDA_ARCHITECTURES=50)
Драйвер NVIDIA	580.178.04
CUDA Toolkit	12.9 (nvcc V12.9.86)
Host-компилятор для nvcc	GNU g++ 14.4.1
Компилятор C++	GNU g++ 15.3.1
CMake / GoogleTest	3.31.11 / 1.15.2
Compute Sanitizer	12.9

Compute capability определена программой tools/device_info.cu: в её выводе получено значение CMAKE_CUDA_ARCHITECTURES=50. Это значение использовано при сборке.

Для запуска вычислений на дискретной GPU потребовалось включить её в работу: по умолчанию устройство обслуживалось открытым драйвером nouveau. Установлен проприетарный драйвер NVIDIA ветки 580 (akmod-nvidia) и CUDA Toolkit 12.9. Дополнительно потребовалась небольшая правка заголовков CUDA 12.9: в glibc 2.42 (Fedora 43) функции cospi, sinpi, rsqrt и их float-варианты объявлены с noexcept, что конфликтует с объявлениями в crt/math_functions.h. В двух заголовках CUDA соответствующим объявлениям добавлен спецификатор noexcept; резервные копии сохранены рядом с исходными файлами. На реализацию алгоритма эта правка не влияет. Перед измерениями включён режим постоянства драйвера и зафиксированы прикладные частоты GPU (nvidia-smi -pm 1 -ac 2505,1019), чтобы уменьшить разброс.

2. Сборка проекта и проверка эталонов (этап 2)

Проект собран только для назначенного алгоритма histogram. Команда конфигурации и сборки:

```

ARCH=50
ALG=histogram
cmake -S nvidia -B build \
  -DLAB_ALGORITHM="$ALG" \
  -DCMAKE_CUDA_ARCHITECTURES="$ARCH" \
  -DCMAKE_BUILD_TYPE=Release \
  -DCMAKE_CUDA_COMPILER=/usr/local/cuda/bin/nvcc \
  -DCMAKE_CUDA_HOST_COMPILER=/usr/bin/g++-14 \
  -DCUDAToolkit_ROOT=/usr/local/cuda \
  -DCMAKE_CUDA_FLAGS="-Wno-deprecated-gpu-targets"
cmake --build build -j4

```

Сборка прошла без ошибок; получены программы build/gtest/test_histogram, build/benchmark/bench_histogram и build/tools/device_info. До реализации собственного алгоритма выполнены проверки групп CPU и Reference:

```

./build/gtest/test_histogram --gtest_filter='CPU.*:Reference.*'
[ PASSED ] 3 tests.

```

Проверки группы CPU содержат малые примеры с известными ответами, Проверки группы Reference сравнивают библиотечную реализацию Thrust с CPU-эталоном. Обе группы пройдены, что подтверждает корректность окружения.

3. Изучение и проектирование алгоритма (этап 3)

CPU-эталон (nvidia/include/cpu_reference.hpp) обнуляет массив счётчиков и последовательно увеличивает нужный счётчик для каждого элемента. Номер счётчика вычисляется по формуле:

$$bin(x) = |int(10 \cdot x)| \bmod bins \quad (1)$$

где $int(\cdot)$ - приведение к типу `int` с усечением дробной части в сторону нуля, а модуль берётся после приведения к `int`. Такой порядок важен для отрицательных x . Число счётчиков `bins` задаётся отдельно от длины массива; по умолчанию `bins = 256`.

Малый пример из набора проверок: $x = \{0; 0,2; 0,1; 0,2\}$, `bins = 4`. Значения номеров счётчиков: 0, 2, 1, 2. Итоговая гистограмма: {1; 1; 2; 0}. Сумма счётчиков равна $N = 4$, что проверяется тестом.

Схема распараллеливания. Базовый вариант - прямое накопление в глобальной памяти: каждый поток независимо вычисляет номер счётчика своего элемента и выполняет `atomicAdd` в глобальный массив. Число глобальных атомарных операций равно N , что при малом числе счётчиков приводит к сильной конкуренции за одни и те же ячейки.

Оптимизированный вариант использует приватную гистограмму блока в разделяемой памяти. Каждый блок: (1) кооперативно обнуляет свою копию гистограммы; (2) после барьера проходит входные элементы с шагом сетки и накапливает их в разделяемой памяти через `atomicAdd`; (3) после второго барьера добавляет накопленные счётчики в глобальную гистограмму. При этом глобальных атомарных операций становится порядка `bins` на блок вместо N . Разделяемая память доступна только внутри блока, поэтому барьер `__syncthreads()` здесь достаточен; межблочная синхронизация не используется - блоки завершают работу независимо, а слияние выполняется атомарными операциями.

Обработка границ. Цикл с шагом по сетке (`grid-stride loop`) обрабатывает неполный последний блок. При $N = 0$ ядро не запускается, а выходной массив обнуляется. Если гистограмма не помещается в разделяемую память (для GTX 860M указано 48 КиБ), код выбирает ядро с глобальными атомарными операциями. Этот резервный путь предусмотрен для больших `bins`, но представленными тестами не проверен: максимальное проверенное значение `bins` равно 257.

4. Реализация CUDA-функции (этап 4)

Реализация размещена только в файле `nvidia/student/histogram.cuh`. Определены вспомогательная функция `histogram_bin`, два `__global__`-ядра и функция-обёртка `student::histogram`. Сигнатура и контракт заготовки сохранены.

Ядро `histogram_shared_kernel` принимает входной указатель, выходной указатель, длину `n` и число счётчиков `bins`. Разделяемая память объявлена как `extern __shared__ int block_hist[]`; её размер равен `bins*sizeof(int)`. Обнуление выполняется кооперативно с шагом `blockDim.x`, поэтому работает и при `bins > blockDim.x`. Накопление и слияние разделены барьерами `__syncthreads()`. Ядро `histogram_global_kernel` используется как базовый вариант при большом `bins`.

Функция `student::histogram` сначала обнуляет выходной массив с помощью `cudaMemsetAsync` в потоке 0 (инфраструктура не инициализирует выход), затем при `N = 0` сразу возвращает управление. Для выбора варианта вычисляется размер разделяемой памяти и сравнивается с `sharedMemPerBlock` устройства. Если гистограмма помещается, размер сетки подбирается через `cudaOccupancyMaxActiveBlocksPerMultiprocessor`: запускается ровно столько блоков, сколько помещается на устройстве, но не больше, чем нужно для покрытия `N`. Иначе запускается базовое ядро с числом блоков, покрывающим массив. Все ядра запускаются в потоке 0; после запуска вызывается `CUDA_CHECK(cudaGetLastError())`. Временных буферов функция не выделяет, поэтому утечек нет; входной массив только читается.

Число потоков в блоке `threads` передаётся извне и реально используется при запуске ядер; исследуются значения 32, 64, 128, 256 и 512.

5. Проверка корректности (этап 5)

После реализации выполнены все проверки назначенного алгоритма. Полный протокол сохранён в `results/tests.xml`, результат запуска `CTest` - ниже:

```
./build/gtest/test_histogram --gtest_output=xml:results/tests.xml
ctest --test-dir build --output-on-failure
  1/3 cpu_reference ..... Passed
  2/3 library_reference ..... Passed
  3/3 student_correctness ..... Passed
100% tests passed, 0 tests failed out of 3
```

Проверки группы Student включают: малый пример; $N = 0, 1, B-1, B, B+1$ и $N = 1003$ для всех B из набора $\{32, 64, 128, 256, 512\}$; режим one-bin; разные значения bins (1, 16, 257); массив из 65 537 и 1 048 576 элементов. Дополнительно тесты повторяют вызов дважды на одних и тех же буферах, чтобы исключить зависимость от предыдущего результата, и проверяют, что входной массив не изменён.

В сохранённом протоколе пройдены 7 тестов в 3 наборах. Проверены пустой вход, некратные размеры, неполный последний блок, bins = 1, 16 и 257, отрицательные значения, повторный вызов и неизменность входа. Корректность пути при bins больше вместимости shared memory остаётся не подтверждённой данным набором тестов.

Дополнительно проведена проверка памяти программой Compute Sanitizer:

```
compute-sanitizer --tool memcheck \
./build/gtest/test_histogram --gtest_filter='Student.KnownExample'
===== ERROR SUMMARY: 0 errors
```

Compute Sanitizer сообщил 0 ошибок при запуске только Student.KnownExample. Протокол этого малого примера сохранён в results/compute_sanitizer.txt; другие размеры этим запуском не проверялись.

6. Базовые измерения производительности (этап 6)

Программа bench_histogram измеряет три метрики. operation_ms - время вызова операции по часам CPU с ожиданием завершения GPU; device_ms - интервал CUDA Events вокруг операции; для CPU поле пустое. end_to_end_ms для GPU охватывает подготовку уже выделенных device-буферов, передачу входа, операцию и получение результата; для CPU оно совпадает с operation_ms. Выделение основных буферов, генерация данных, проверка и запись CSV находятся вне измеряемых интервалов. Реализации чередуются в одной сессии. Фоновая нагрузка и изменение частот всё равно

могут влиять на разброс, поэтому выводы ниже опираются на повторы и медианы.

Первый запуск выполнен при N = 65 536, B = 256, warmup 3, repeat 10:

```
./build/benchmark/bench_histogram \
--n 65536 --threads 256 --warmup 3 --repeat 10 \
--impl all --csv results/baseline.csv
```

Таблица 2 - Базовые измерения (N = 65 536, B = 256, среднее по 10 повторам)

Реализация	operation_ms	device_ms	end_to_end_ms
CPU	0,253035	-	0,253035
Собственный CUDA	0,258161	0,255382	0,414866
Thrust	0,373975	0,371363	0,554613

В базовом режиме end_to_end_ms включает передачу входа на устройство и получение результата, поэтому полное время GPU-реализаций больше времени CPU при данном N. Библиотечная реализация histogram составлена из набора Thrust-операций (вычисление номеров, сортировка, поиск верхних границ и разности), поэтому её трудоёмкость принципиально отличается от прямого подсчёта.

7. Повторяемость измерений (этап 7)

Для оценки разброса выполнено 30 измеряемых повторов при неизменных данных и настройках, после чего построена сводка:

```
./build/benchmark/bench_histogram \
--n 65536 --threads 256 --warmup 3 --repeat 30 \
--seed 42 --impl all --csv results/repeats.csv
python3 scripts/summarize.py \
--csv results/repeats.csv --out results/repeats_summary.csv
```

Таблица 3 - Повторяемость (N = 65 536, B = 256, 30 повторов, медиана)

Реализация	Медиана operation_ms	Медиана end_to_end_ms	СКО end_to_end_ms	Мин / макс end_to_end_ms
CPU	0,227041	0,227041	0,048147	0,21078 / 0,39129
Собственный CUDA	0,150977	0,378837	0,132958	0,23742 / 0,91958
Thrust	0,366505	0,584064	0,143200	0,42308 / 1,17637

Разброс времени объясняется накладными расходами запуска ядер, передачей данных и влиянием других процессов, частот и нагрева GPU. Медиана устойчивее среднего, поэтому для сравнения реализаций далее

используются медианы. Все сравниваемые реализации запускались на одной машине в одной сессии, что делает сравнение корректным.

8. Серии по размеру данных и блоку (этап 8)

Полная серия измерений получена для N из набора {1 024; 16 384; 65 536; 1 048 576} и B из набора {32; 64; 128; 256; 512}, по 10 повторов:

```
python3 scripts/run_series.py \
  --exe build/benchmark/bench_histogram \
  --sizes 1024 16384 65536 1048576 \
  --blocks 32 64 128 256 512 --repeat 10 --out results/series.csv
python3 scripts/summarize.py \
  --csv results/series.csv --out results/series_summary.csv
```

На рисунке 1 показана медиана end_to_end_ms от размера N для трёх реализаций (для собственной реализации выбран B = 256).




Рисунок 1 - Медиана end_to_end_ms от размера N

При малом N собственная GPU-реализация проигрывает CPU по end_to_end_ms из-за затрат на запуск операции и подготовку данных. При N = 1 048 576 её медиана end_to_end_ms ниже медианы CPU и Thrust. Однако доля времени вне operation_ms при росте N не уменьшается: для B = 256 она

составляет около 20 % при $N = 1024$ и около 86 % при $N = 1\,048\,576$. Эта разница включает передачу данных и подготовку буферов.

Таблица 4 - Собственная реализация: медианы operation_ms / end_to_end_ms, мс

$N \setminus B$	32	64	128	256	512
1 024	0,110 / 0,135	0,088 / 0,105	0,162 / 0,195	0,120 / 0,150	0,118 / 0,144
16 384	0,125 / 0,231	0,161 / 0,256	0,159 / 0,266	0,128 / 0,225	0,142 / 0,233
65 536	0,151 / 0,371	0,172 / 0,373	0,211 / 0,386	0,160 / 0,363	0,165 / 0,417
1 048 576	0,689 / 4,368	0,620 / 4,526	0,586 / 4,476	0,596 / 4,297	0,546 / 4,644

На рисунке 2 отдельно показано влияние размера блока B при $N = 1\,048\,576$.




Рисунок 2 - Собственная реализация: медианы времени от B при большом N

На рисунке 3 приведены кривые времени собственной реализации от N для каждого B .




Рисунок 3 - Собственная реализация: end_to_end_ms от N для разных B

При $N = 1\,048\,576$ наименьшая измеренная медиана end_to_end_ms получена для $B = 256$: 4,297 мс. Разница с $B = 32$ составляет лишь 0,071 мс, тогда как выборочное СКО при $B = 256$ около 0,776 мс (для остальных B - 0,529-0,655 мс). Поэтому устойчивый оптимум по этим измерениям не установлен. Влияние неполных блоков, пропускной способности памяти и времени барьеров отдельно не измерялось.

Дополнительные эксперименты по характеру входных данных ($N = 1\,048\,576$, $B = 256$):

Таблица 5 - Специальные режимы (медиана 10 повторов, мс)

Режим	CPU operation_ms	CUDA operation_ms	CUDA end_to_end_ms	Thrust end_to_end_ms
random, bins = 16	6,86278	0,72858	4,69293	8,15924
random, bins = 256	6,81935	0,44559	4,27192	8,28160
one-bin (все x = 0)	6,43560	0,76517	4,31234	7,61187

В режиме one-bin все значения направлены в один счётчик, что усиливает конкуренцию атомарных операций в shared memory. Медианы operation_ms составили 0,72858 мс при bins = 16, 0,44559 мс при bins = 256 и

0,76517 мс в режиме one-bin. Разница относительно bins = 256 значительна для самой операции - около 64 % и 72 % соответственно; по end_to_end_ms она меньше из-за затрат вне операции. Thrust-эталон включает сортировку, поэтому его время отражает другую последовательность операций.

9. Анализ результатов и выводы (этап 9)

Практическое ускорение оценивалось по формуле:

$$S_{full} = T_{CPU,operation} / T_{GPU,end_to_end} \quad (2)$$

Для сравнения вычислений над уже подготовленными буферами дополнительно приведено отношение operation_ms (в него не входят передача входа и получение результата).

Таблица 6 - Ускорение при B = 256 (медианы)

N	CPU operation_ms	CUDA operation_ms	CUDA end_to_end_ms	S_full	S_operation
1 024	0,003518	0,119851	0,149821	0,023	0,029
16 384	0,055388	0,127681	0,225191	0,246	0,434
65 536	0,223633	0,159558	0,363051	0,616	1,402
1 048 576	6,499721	0,596196	4,297162	1,513	10,902

При малых N $S_{full} < 1$: в заданных границах измерения GPU медленнее CPU. При N = 1 048 576 $S_{full} = 6,499721/4,297162 \approx 1,51$, а отношение operation_ms равно $6,499721/0,596196 \approx 10,90$. При этом доля времени GPU вне operation_ms растёт с размером N; выигрыш возникает потому, что измеренное CPU-время растёт быстрее полного GPU-времени.

На время влияют число операций, обращения к памяти, атомарное накопление и подготовка данных. Собственная реализация сначала обнуляет выход, затем выполняет одно вычислительное ядро с блоковой гистограммой; глобальных атомарных слияний порядка bins на блок, но внутри блока остаются атомарные операции и два барьера. Thrust-эталон использует transform, sort, upper_bound и adjacent_difference, поэтому сравниваются разные алгоритмические схемы. Рост времени вне operation_ms при большом N виден в данных, но вклад передачи, очистки и иных расходов

по отдельности не измерялся; насыщение пропускной способности GPU аппаратными метриками также не проверялось.

С ростом N медиана времени собственной реализации увеличивается медленнее, чем у CPU, поэтому в наибольшем измеренном режиме наблюдается практическое ускорение. Различия между размерами блока при $N = 1\,048\,576$ малы относительно разброса; $B = 256$ - лучший из проверенных по медиане `end_to_end_ms` в этой серии, без доказательства устойчивого оптимума.

Заключение

В работе реализован и исследован вариант 6 - histogram - собственными CUDA-ядрами. Сохранённые проверки подтверждают корректность для пустого входа, некратных размеров, `bins = 1, 16, 257` и массивов до $1\,048\,576$ элементов; вход не изменяется. 7 тестов GoogleTest и 3 проверки CTest прошли успешно, Compute Sanitizer сообщил 0 ошибок для малого Student.KnownExample. Резервный путь для гистограммы, не помещающейся в shared memory, реализован, но в протоколе не проверен. При $N = 1\,048\,576$ и $B = 256$ практическое ускорение относительно CPU по `end_to_end_ms` составило 1,51; преимущество над Thrust относится к сравниваемым здесь разным схемам построения гистограммы.

Список использованных источников

1. Лабораторная работа №2. Базовые параллельные примитивы на GPU: методические указания / ИТМО, факультет ПИиКТ. - Санкт-Петербург, 2026. - 15 с.
2. AVSII. Лекция 2. Подсистема памяти современных процессоров / И. В. Лукашов. - Санкт-Петербург: ИТМО, 2026.
3. NVIDIA CUDA C++ Programming Guide. - URL: <https://docs.nvidia.com/cuda/cuda-c-programming-guide/> (дата обращения: 06.10.2026).
4. NVIDIA CUDA C++ Best Practices Guide. Performance Metrics. - URL: <https://docs.nvidia.com/cuda/cuda-c-best-practices-guide/> (дата обращения: 06.10.2026).
5. CMake Documentation. CMAKE_CUDA_ARCHITECTURES. - URL: https://cmake.org/cmake/help/latest/variable/CMAKE_CUDA_ARCHITECTURES.html (дата обращения: 06.10.2026).
6. Thrust Documentation. - URL: <https://nvidia.github.io/cccl/thrust/> (дата обращения: 06.10.2026).
7. ГОСТ 7.32-2017. Система стандартов по информации, библиотечному и издательскому делу. Отчёт о научно-исследовательской работе. Структура и правила оформления. - Москва: Стандартинформ, 2017.